

GlobalShop Direct

Segmenter les clients avec la méthode RFM

Brief Machine Learning non supervisé

R

Récence

F

Fréquence

M

Montant

PRÉSENTATION

L'équipe



Ludivine



Zohair

LE PROJET

Une question simple. Qui sont nos clients ?

LE CLIENT

GlobalShop Direct, plateforme e-commerce britannique.

LA DEMANDE

Sa direction marketing veut segmenter ses clients pour mieux les cibler.

LES DONNÉES

541 909 lignes de transactions du 01/12/2010 au 09/12/2011 en livres sterling (£).

La méthode RFM

R Récence : jours depuis le dernier achat

F Fréquence : nombre de commandes

M Montant : total dépensé

LES 4 RENDUS

[Diapo](#)[Notebook](#)[Simulateur Streamlit](#)[Tableau de bord Data Studio](#)

LA DÉMARCHE

De 541 909 transactions à 6 segments clients

1

Explorer

2

Nettoyer

3

Construire le
RFM

4

Préparer les
variables

5

Segmenter

6

Interpréter

7

Livrer

541 909

lignes brutes

4 321

clients

6

segments

Une base brute pleine de pièges

541 909

lignes et 8 colonnes. Une ligne est un produit dans une facture et pas un client. Il faudra regrouper par client.

135 080

lignes sans id client (24,93 %). Impossible de les rattacher à un profil RFM.


5 268

lignes identiques (environ 1 %). Elles gonflent le Montant des clients concernés.

Valeurs négatives

Certaines quantités sont négatives (jusqu'à -80 995) et certains prix aussi (jusqu'à -11 062 £). Ce sont des annulations ou des écritures comptables et pas des ventes.

Les annulations




3 266 totales · 4 670 partielles · 693 hors période · 276 codes particuliers

Les factures qui commencent par « C » sont des annulations. 8 905 ont un client.

Le problème. L'annulation ne supprime pas l'achat d'origine. Retirer seulement les lignes « C » laisse des montants faux.

Autres intrus. Frais de port, frais Amazon, commissions, remises, saisies manuelles et bons cadeaux.

Trois constats qui orientent le nettoyage



Nombre de factures par mois. Décembre 2011 s'arrête le 9.

PAYS

38 pays. Le Royaume-Uni pèse 91 % des lignes et 90 % des clients.

On garde tous les pays car on segmente sur le comportement d'achat.

SAISONNALITÉ

Activité stable de janvier à août puis un pic en novembre (près de 3 500 factures).

Point d'attention. Une bonne Récence ne veut pas forcément dire client fidèle.

VALEURS EXTRÊMES

Les deux plus grosses quantités (74 215 et 80 995) ont été annulées 12 à 16 minutes après.

Elles partent avec les annulations totales. Les vrais grossistes restent.

NETTOYAGE

Nettoyer dans le bon ordre

Étape	Retirées	Reste
Lignes sans id client	135 080	406 829
Doublons	5 225	401 604
Codes non-produits	1 911	399 693
Annulations hors période	692	399 001
Annulations totales	5 610	393 391
Prix nuls	34	393 357

Annulations totales : on retire l'achat et son annulation (2 805 paires). Elles étaient 3 266 à l'exploration. Ici l'achat doit être avant l'annulation et un achat ne sert qu'une fois. Les annulations partielles restent et sont déduites du montant.

393 357

lignes restantes (27 % retirées)

4 324

clients. 48 ont disparu car toutes leurs lignes ont été supprimées.

CONSTRUCTION DU RFM

Une ligne par client

R Récence

Jours depuis le dernier achat

De 1 à 374 jours. Médiane de 51.

F Fréquence

Nombre de commandes

Médiane de 2. Maximum de 203.

M Montant

Total dépensé avec les retours déduits

Médiane de 653 £. Moyenne de 1 908 £.

DATE DE RÉFÉRENCE


Le 10/12/2011, soit le lendemain de la dernière facture. 3 clients au montant nul ou négatif sont retirés. Il reste **4 321 clients**.

VÉRIFICATION À LA MAIN


Le client 16446 a une commande de 2,90 £ et un dernier achat il y a 206 jours. Sans le nettoyage il aurait eu 168 000 £ et une Récence de 1 jour.

Préparer les variables pour le clustering

AVANT LE LOG



APRÈS LOG1P



K-Means calcule des distances. Quelques très gros clients écraseraient tous les autres.


Asymétrie	Avant	Après
Récence	1,24	-0,33
Fréquence	11,84	1,22
Montant	21,65	0,36

Coefficient d'asymétrie (skew). Ce n'est ni une moyenne ni une médiane. Proche de 0 la distribution est symétrique. Plus il est grand plus quelques gros clients tirent vers la droite.


StandardScaler met les 3 variables à la même échelle (moyenne de 0 et écart-type de 1).

rfm garde les vraies valeurs pour interpréter. **rfm_log** sert au modèle.

Combien de groupes ?



Coude le plus net à K = 2. Pas franc ensuite.



Meilleur score à K = 2 (0,433). K = 3 : 0,340. K = 4 : 0,337.

K = 4

Par rapport à K = 3 il coupe les clients moyens en deux. D'un côté des clients récents qui achètent peu. De l'autre de bons clients qui commencent à s'éloigner. La silhouette reste presque la même.

Que fait chaque paramètre ?

Paramètre	Ce qu'on a vu
init : placement des centres	k-means++ et random donnent la même inertie (3 887,6). random met 28 tours contre 15.
n_init : nombre de relances	L'inertie baisse un peu (3 887,6 à 3 887,1) puis ne bouge plus entre 10 et 20 relances.
max_iter : tours maximum	Avec 2, 5 ou 10 tours le modèle s'arrête trop tôt. Avec 300 il s'arrête seul au bout de 28 tours.

Toutes les combinaisons : dès qu'il y a assez de tours le résultat est entre 3 887,0 et 3 887,6. Le pire cas est random avec 1 lancement et 10 tours (3 946,4).

RETENU

init = k-means++

n_init = 20


max_iter = 300

Inertie de 3 887,0

Silhouette de 0,338

Clusters de 707 à 1 568 clients

Classification ascendante hiérarchique



On part de chaque client seul. On fusionne à chaque étape les deux groupes les plus proches.

Le dendrogramme propose $K = 4$ ou $K = 6$ (silhouette de 0,271 et 0,268). $K = 6$ sépare les clients perdus (720) des clients à risque (896). Le plus petit groupe fait 276 clients.

Modèle final. ward avec $K = 6$. Silhouette de 0,268.

ward • retenu

Groupes équilibrés de 276 à 1 118 clients.

single

Silhouette de 0,387 mais 4 315 clients dans un seul groupe.

average

3 496 clients dans un seul groupe.

complete

Silhouette la plus basse (0,195).


COMPARAISON DES DEUX MODÈLES

K-Means ou CAH ?

Silhouette	K-Means	CAH
K = 4	0,338	0,271
K = 6	0,314	0,268

Les deux modèles concordent sur les extrêmes. Les 720 perdus de la CAH sont tous dans les perdus de K-Means.


K-Means à 6 retrouve les segments utiles de la CAH. Il sépare en plus les fidèles selon leur volume d'achat (634 gros fidèles et 656 actifs récents). Il dépend moins du rush de Noël.



MODÈLE FINAL K-Means à 6 clusters

RÉDUCTION DE DIMENSION

PCA : voir les 6 groupes en 2D



94 %

de l'information gardée avec 2 axes sur 3

AXE 1 · 75,4 %

Valeur du client.

Fréquence (0,62) et
Montant (0,60) contre
Récence (-0,51).

AXE 2 · 18,6 %

Ancienneté du dernier

achat. Récence (0,85) et
un peu de Montant (0,45).

Six zones distinctes qui se touchent sans se mélanger. L'élite est isolée à droite et très étalée.

Pourquoi 6 segments et qui sont-ils ?

POURQUOI 6 ET PAS 4

Des actions différentes. Avec 4 groupes les clients à risque sont mélangés avec les perdus. Pourtant ils demandent des actions marketing différentes.

Des fidèles mieux séparés. Les Fidèles et les Prometteurs n'ont pas le même volume d'achat (2 461 £ contre 1 016 £).

Des groupes assez grands. Le plus petit fait 316 clients. Chaque segment peut être ciblé.

Champions

316 clients

5 jours, 15 commandes, 5 675 £

Achète très souvent et beaucoup.
Vient d'acheter.

Prometteurs

656 clients

10 jours, 4 commandes, 1 016 £

Achète régulièrement et récemment.
Peut devenir fidèle.

À risque

929 clients

94 jours, 2 commandes, 825 £

Bon client qui ne revient plus depuis 3 mois.

Fidèles

634 clients

32 jours, 6,5 commandes, 2 461 £

Client régulier avec de gros paniers.

Occasionnels

821 clients

34 jours, 1 commande, 294 £

A acheté une fois récemment avec un petit panier.

Perdus

965 clients

240 jours, 1 commande, 218 £

Venu une fois il y a plus de 7 mois.

BILAN TECHNIQUE

Ce qu'on retient et ce qui reste limité

LE PARCOURS

541 909 lignes brutes, 393 357 lignes après nettoyage, 4 321 clients et 6 segments.

LE POINT CLÉ

Le traitement des annulations. Les totales sont supprimées avec leur achat d'origine. Les partielles sont déduites du montant.

LE MODÈLE FINAL

K-Means à 6 clusters. Silhouette de 0,314 contre 0,268 pour la CAH. La PCA garde 94 % de l'information en 2 axes.


LES LIMITES

- La silhouette reste modeste. Les clients forment un continuum sans vrais trous. Les frontières sont floues.
- Un seul an de données.
- Date du premier achat inconnue pour les clients d'avant décembre 2010.
- Les produits achetés par segment n'ont pas été analysés. C'est une piste pour la suite.

REPRODUCTIBILITÉ

Refaire exactement le même chemin

Le simulateur doit ranger un nouveau client comme le notebook l'a fait. On sauvegarde donc les mêmes objets avec **joblib** puis on les recharge.



100 %

des 4 321 clients retrouvent le même cluster que dans le notebook après rechargement des fichiers.

TEST À LA MAIN

Un client de 3 jours, 7 commandes et 4 310 £ tombe dans le cluster 2. C'est le segment Champions avec la bonne action.

POUR ALLER PLUS LOIN

SIMULATEUR

Simulateur Streamlit

On passe sur le simulateur.

[Ouvrir le simulateur](#)

ANALYSE

Tableau de bord Data Studio

On va sur l'analyse des données.

[Ouvrir le tableau de bord](#)